Informe de Validación Técnica: Implementación de Redes Neuronales Convolucionales (CNN) para la Clasificación de Textiles

Proyecto: Arquitectura StyleNet

Área: Inteligencia Artificial / Deep Learning

1. Resumen Ejecutivo

El presente informe documenta el diseño, entrenamiento y despliegue de un modelo de aprendizaje profundo (Deep Learning) orientado a la clasificación automatizada de prendas de vestir. A través de un enfoque comparativo, se validó la superioridad de las arquitecturas convolucionales frente a los modelos densos tradicionales en tareas de visión computacional.

2. Especificaciones de la Arquitectura del Modelo

Se implementó una Red Neuronal Convolucional (CNN) optimizada para procesar tensores de entrada de $28 \times 28 \times 1$. La arquitectura se fundamenta en los siguientes componentes:

Extracción de Características: Dos capas de Convolución (Conv2D) con 32 y 64 filtros, encargadas de la detección de patrones jerárquicos (bordes, texturas y formas complejas).

Reducción Dimensional: Capas de Max-Pooling para optimizar la carga computacional y extraer las características más invariantes.

Regularización Estocástica: Se integró una capa de Dropout (0.3) para mitigar el overfitting (sobreajuste), garantizando que los pesos del modelo no se memoricen el ruido del dataset de entrenamiento.

Capa de Inferencia: Una capa densa final con activación Softmax, que normaliza la salida en una distribución de probabilidad sobre 10 categorías discretas.

Cuadro Comparativo de Métricas

Métrica de Desempeño	Red Neuronal Densa (Baseline)	CNN (StyleNet)
Accuracy (Exactitud)	87.72%	90.45%
Loss (Función de Pérdida)	0.35	0.26
Convergencia	Estándar	Optimizada (Adam)

3. Bitácora de Resolución de Incidencias Técnicas

Durante el ciclo de vida del desarrollo (SDLC), se identificaron y subsanaron los siguientes eventos críticos:

Inconsistencia en el Entorno Virtual: Errores de resolución de dependencias en el módulo tensorflow.python.

Resolución: Sincronización del intérprete de Python 3.12 y reconstrucción del entorno venv.

Desviación en el Preprocesamiento: El modelo presentaba una matriz de confusión elevada entre las categorías "Shirt" y "T-shirt".

Resolución: Ajuste en el pipeline de entrada para invertir la escala de grises y normalizar los valores de los píxeles al rango $[0,1]$, alineando los datos externos con la distribución estadística del dataset Fashion-MNIST.

4. Optimización del Hiperparámetro de Épocas

El proceso de entrenamiento se dividió en dos fases de validación:

Fase de Iteración Inicial (5 épocas): El modelo mostró una convergencia prematura con una capacidad de generalización limitada ante datos no vistos.

Fase de Optimización (15 épocas): Tras el análisis de las curvas de aprendizaje, se determinó incrementar las iteraciones a 15 épocas. Esta decisión permitió un ajuste más fino de los pesos sin incurrir en divergencia, logrando una clasificación exitosa de imágenes capturadas manualmente con un margen de confianza superior al 50%.

5. Despliegue de Interfaz de Usuario (Streamlit)

Para facilitar la interacción con el modelo y la visualización de inferencias, se desarrolló una interfaz funcional en Streamlit. Esta capa de aplicación permite:

Carga dinámica de archivos (File Uploader).

Procesamiento de tensores en tiempo real.

Visualización interactiva de la distribución de probabilidades mediante gráficos de barras (Plotly).

6. Conclusiones

La implementación de la arquitectura CNN representó una mejora cuantitativa del 3% en la precisión respecto al modelo base. La transición de un script de consola a una aplicación web interactiva demuestra la viabilidad de integrar modelos de IA en entornos productivos, asegurando la entrega de diagnósticos rápidos y visualmente interpretables.

GIANINA JENSEN GUZMÁN